人工智能基础 Project 1 实验报告

——卷积神经网络(CNN)

0. 摘要

卷积神经网络(Convolutional Neural Networks, CNN)广泛应用于计算机视觉等领域，是自动驾驶等先进技术的基础。为了深入了解其训练和预测的基本流程、探究神经网络设计对模型性能的影响，我利用 CIFAR-10 数据集对神经网络进行训练，调整超参数和网络结构以探究其影响，并绘制曲线使其可视化。

1. 引言

自动驾驶、人脸识别等技术的发展对计算机图像识别有着很高的要求，而神经网络能够实现计算机对图像的深度学习，从而随着学习的深入达到更高的识别精度。但学习过程的无限延长并不能带来模型准确率的无限提升，不同的网络结构和超参数设计使不同模型的精度上限也有差异。通过对神经网络设计的调整，我希望给出更精准、更高效的模型。

本次实验通过 CIFAR-10 数据集对卷积神经网络进行训练、预测结果并与真实标签比较，得到训练过程中的损失(Loss)与预测结果的准确率(Accuracy)。其中，Loss 描述了训练过程中模型的预测值与真实值之间的差距，是表征训练进度的重要指标，Loss 越小则模型的预测结果将会越精确；Accuracy 是模型在预测过程中产生正确结果的频率，直接反映了模型的预测性能。

实验代码基于 Python 3 和 Pytorch。构建神经网络的基础代码已经给出或可以从 Internet 中得到，我在实验中对它们进行了必要的修改以满足我的实验需求。此外我自主添加了对网络结构和超参数微调的代码并将结果可视化，模型的性能通过 Accuracy 体现。早期卷积神经网络 LeNet 在测试中 Accuracy 稳定在 60%附近，而引入正则化或采用 AlexNet 等现代卷积神经网络对结果有影响；增加训练轮数能使 Accuracy 趋于模型上限，而其他超参数则有最优取值区间。

2. 方法

本实验旨在理解 CNN 对图像的多层处理方式，体会通过迭代对参数进行优化进而提高模型精度的过程，并通过对网络结构的改变和对超参数的微调尝试发现神经网络设计的更优选择。

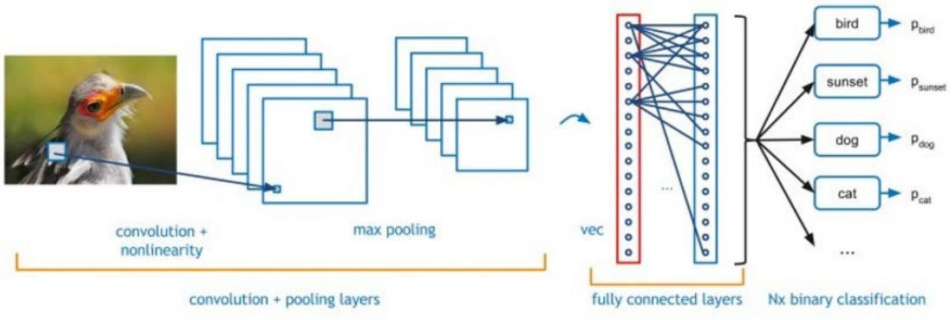


***Figure 1: Image of the working principle of Convolutional neural networks* (Guo, 2016).**

为理解神经网络的工作方式，我首先基于基础代码构建的 LeNet 网络进行训练，并测试其结果。该神经网络分为卷积层(Convolutional Layer)、最大池化层(Max Pooling Layer)、全连接层(Fully Connected Layer)，将图片简化处理、提取关键信息后进行分析，最终作出判断，其过程大致可用 Figure 1 描述。在代码中，我引入了 List 用来存储训练过程中的 Loss 值以利用 Matplotlib 绘制 Loss 曲线，相关修改已在代码中通过注释标明其目的和所属 Task（其他修改也以同样的形式标注，但具体 Task 下自主构建的代码未作过多标注）。

此外，我在模型中加入了正则化以调整网络结构。其中 L_2 正则化通过将模型系数的平方添加到 Loss 函数中，防止系数的数值过大，减少模型的复杂性，进而防止过拟合，实验中通过在 SDG Optimizer 中引入 weight_decay（默认值为 0，即无 L_2 正则化）实现。而 Dropout 正则化通过随机关闭神经网络中一定比例的神经元，避免产生过度依赖，从而防止过拟合，实验中通过在两个线性层中引入 Dropout 层并确定 Dropout Rate 即可实现。

训练过程设定了一些超参数，如训练轮数(Number of Epochs) num_epochs，学习率(Learning Rate) lr，动量(Momentum) momentum，权重衰减(Weight Decay) weight_decay 等。对它们进行调节并观察模型性能，可以指导神经网络设计。实验中我通过查阅资料，设定各超参数默认值分别为 lr=0.001, momentum=0.9, weight_decay=0.0001, num_epochs 视情况而定。分别微调各超参数，并绘制模型 Accuracy 与其的关系曲线，可得出实验条件下各超参数的最优取值区间。在模型预测取得相近效果时，尝试缩短训练时间。

最后，我采用了现代卷积神经网络 AlexNet 进行训练与测试。相较于 LeNet，AlexNet 结构更为复杂，拥有更多数量和种类的 Layer，其中就包括 Dropout 层。这使得模型可以进行更加深入的学习，但也延长了训练所需的时间。

3. 实验

3.1 实验设置

本实验利用 CIFAR-10 数据集对神经网络进行训练和测试。该数据集分为飞机、汽车、鸟、猫、鹿、狗、青蛙、马、船和卡车 10 类，每个类别有 6000 张图像。由于其较小的图像尺寸和简明的图像分类，CIFAR-10 数据集广泛运用于图像识别的机器学习。

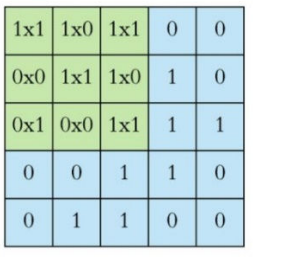


Figure 2: First step of the filtering process (Dertat, 2017).

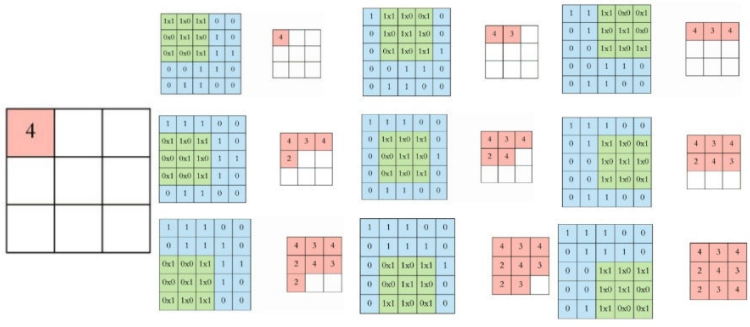


Figure 3: Full process of getting the convolution (Dertat, 2017).

上面“方法”部分已经概述了实验中的网络结构，接下来我将具体阐释各个 Layer 的原理和作用。计算机中图像由像素构成，我们可以采用一个 5*5 的灰度图像来解释这一过程。在卷积层(Convolutional Layer)中，假设我们使用一个大小为 3*3 的 Filter 来处理图像，这个 filter 的过程就在进行卷积(Figure 2)。对原始图像的每一个 3*3 部分都如此处理，就完成了整个卷积过程(Figure 3)。

在卷积之后进行池化可以降低图像的维度，从而减少参数的数量、缩短训练时间，并且避免过拟合。本实验采用最大池化层(Max Pooling Layer)，例如对于一个4*4的矩阵，将其等分成4份后分别取最大值，就将其缩减为了一个2*2的矩阵(Figure 4)。Max Pooling在削减长宽的同时保持了深度。

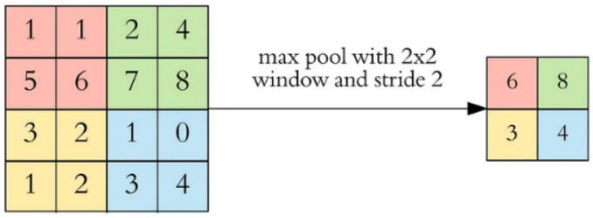


Figure 4: Example of the process of Max Pooling Layer (Dertat, 2017).

全连接层(Fully Connected Layer)的主要作用是进行分类。先前卷积层和池化层提取的图像特征在此进行汇总，根据每个神经元的权重进行不同的反馈，最终通过调整权重和网络得到分类结果。

实验中超参数的默认值亦在“方法”部分说明。在探究这些超参数的最优取值时，无关项设置为默认值，目标项的取值区间分别设置为：num_epochs 1-50, lr 0-0.010, momentum 0.65-0.98, weight_decay 0-0.0061。这些区间都将默认值包含在内，以在默认值附近探究最优取值。

3.2 实验结果

实验利用基础代码构建的LeNet网络进行训练，同时追踪其Loss值，并测试其Accuracy。我先利用基础代码中给出的方法进行追踪，得到Loss曲线如Figure 5左图所示，可以观察到每一个Epoch内Loss值都有起伏变化，但总体表现为下降。为了更直观地展示随着训练轮数增加Loss值的总体变化趋势，我对代码进行了修改，对每个Epoch求平均Loss，得到Loss曲线如Figure 5右图所示。随着训练的进行，表征预测值与真实值之间的差距的Loss值不断降低，说明模型在训练集上的拟合效果不断增强，也更可能在测试中达到更高的Accuracy。本次实验都测试中模型的Accuracy达到了63%。

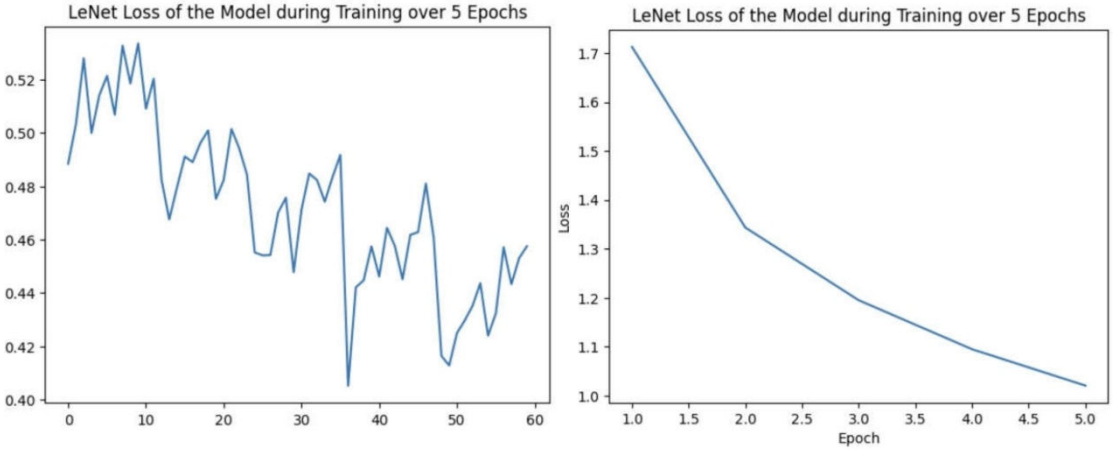


Figure 5: The loss of LeNet model over a training time of 5 epochs

在早期卷积神经网络LeNet的基础上引入L_2正则化和Dropout正则化，重新进行训练和测试，模型的Accuracy为59%。由于原始模型并没有发生过拟合，模型的精度并没有提升，但也没有明显降低。

将实验中的Epoch数提升到50，训练所需时长明显延长，但Accuracy始终稳定在60%附近，如Figure 6所示（单位：%，下同），这说明实验条件下模型精度已达上限。由于在之前的训练过程中参数已经收敛到较精确的值，继续延长训练过程并没有提升模型精度，反而耗费更多时间。

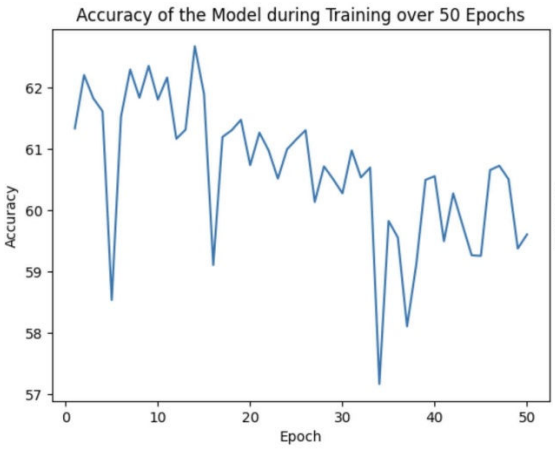


Figure 6: The accuracy of LeNet model over a training time of 50 epochs

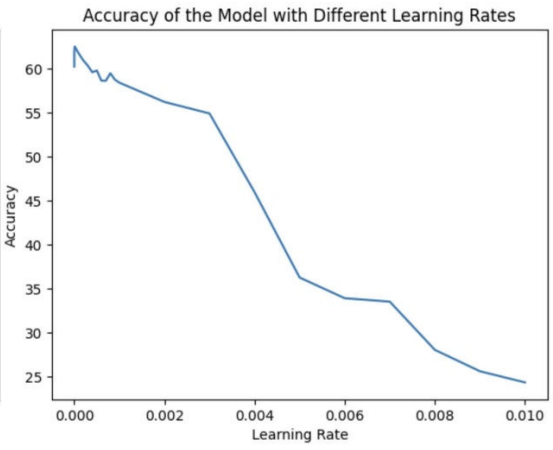


Figure 7: The accuracy of LeNet model with different learning rates

Learning Rate 用于控制训练过程中每次迭代的步长，即学习的速率。对其进行微调，可以得到 Accuracy 曲线如 Figure 7 所示。实验中 Learning Rate 接近 0 时，Accuracy 保持在较高的 60%左右，这是由于模型经过之前的多轮训练参数已经得到优化，不需要大幅度的学习即可达到较高精度。而随着 Learning Rate 逐步放大，模型参数很难在训练中收敛，故 Accuracy 急剧下降。实验中，0.001 以下的 Learning Rate 都给出了较好的预测结果，但在实际训练中，将其设置过小可能需要较长时间才能使模型达到好的效果。

Momentum 类似于力学中的动量，用于减少震荡、加速收敛。观察 Figure 8 可以发现，Momentum 过小或过大均会导致学习率降低，将其设置在 0.90-0.95 内可以得到较好的训练效果。实验中 Accuracy 整体偏低，这是因为本轮实验中训练 Epoch 数较少。

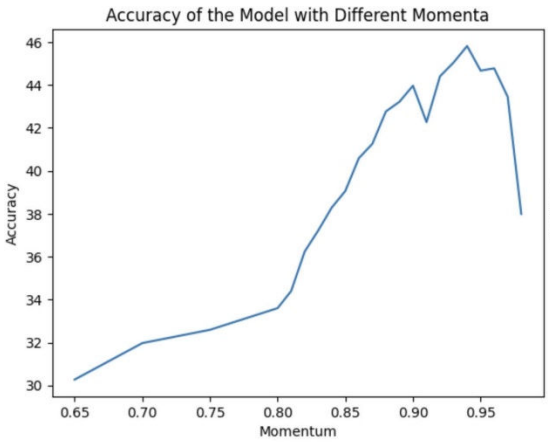


Figure 8: The accuracy of LeNet model with different momentums

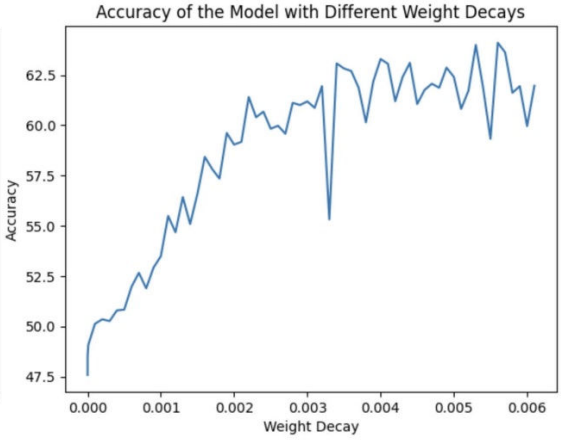


Figure 9: The accuracy of LeNet model with different weight decays

Weight Decay 是在 L_2 正则化中引入的系数，表征对系数的数值过大的惩罚力度，用于降低模型复杂性、防止过拟合。实验得到该参数设置不同时 Accuracy 变化曲线，实验中 0.003-0.006 的 Weight Decay 都得到了较好的结果。但该实验设计并不完善，实验中训练 Epoch 数较少，模型本身在学习过程中 Accuracy 也能逐渐提升。不过，引入这一超参数对原始模型的精度仍稍有改善。

最后，我参照 Internet 中的代码构建了现代卷积神经网络 AlexNet，并在 CIFAR-10 数据集上训练、测试。由于时间有限，训练进行了 10 Epochs，可以发现模型 Loss 逐步降低，在测试中的 Accuracy 也由近乎随机的 10%提升到了 50%左右，并有进一步提升趋势，有望超过 LeNet。

4. 总结

本次实验通过对 CNN 中 LeNet 与 AlexNet 两种神经网络的训练与测试，体会了其通过分层抽取图像特征达到图像识别的共同思路，也比较了不同网络结构对模型预测效果的影响。实验发现，传统的 LeNet 在 CIFAR-10 数据集上可以达到约 60%的 Accuracy，而采用不同的网络结构则会有不同的精度。实验中为了达到这一精度上限，需要对超参数进行合理的设置，并对模型进行足够时长的训练。从实验设计来看，本次实验在某些自主进行的实验模块中仍不够完善，还需要进一步学习以提升实验设计水平。从实验结果来看，本次实验训练的模型在图像识别方面的精度还有待提高，与现代神经网络的水平或需求也有较大差距。相信在未来，我个人在这方面的知识和能力能够进一步提升，相关领域的不断发展也能为人们都生活带来更多便利。