人工智能基础 Project 2 实验报告

——文本情感分类方法探究与分析

0. 摘要 Abstract

对文本情感进行分类有助于分析人们的情感态度，为公司产品、政府政策等提供反馈，从而指导更具针对性的决策制定。本实验通过不同方式对文本分类模型进行训练并尝试调整超参数，在实验中探究了文本处理的基本过程和模型分类的特点，并为更好地利用模型进行文本情感分类提供思路。

1. 引言 Introduction

当今我们正处于信息时代，文本数据量呈爆发式增长，这为自然语言处理(Natural Language Processing, NLP)技术提供了广阔的应用前景，其中文本情感的分析便对企业、政府等的决策制定有着很强的指导意义。通过对预训练的模型进行微调，我们可以快速获得拥有较高准确率的模型。

本次实验使用文章 CARER: Contextualized Affect Representations for Emotion Recognition (Saravia et al., EMNLP 2018)中的情感分析数据集对 DistilBERT 模型进行训练、预测结果并与真实标签比较，计算其在测试中的准确率(Accuracy)和 F1 值(F1)。其中，Accuracy 是模型测试结果正确的频率，直接反映了模型的预测性能；F1 则对模型的准确率和召回率进行了综合评判，当模型在不平衡数据集上偏向频率更大的类别时，模型的 Accuracy 可能很高，此时相对较低的 F1 便能反映出训练中的问题。

实验代码基于 Python 3 和 Pytorch。实验所需的基础代码已经给出或可以从 Internet 中得到，我对它们进行了必要的修改以满足我的实验需求。此外我自主添加了对超参数微调的代码并将结果可视化，模型的性能通过 Accuracy 与 F1 体现。实验中增加训练轮数能使模型效果趋于上限，而其他超参数则有最优取值区间；分析预测结果中与真实值相差最大和最小的样本，可以发现模型能够十分精准地识别特定的情感类别，但也容易将其他类别的情感误判为该类。

2. 方法 Methodology

本实验旨在理解自然语言处理的多个步骤和训练分类模型的不同方法，通过对超参数进行微调探究其影响，分析模型的预测结果以了解其特性，最终有针对性地构造对抗样本以检测其鲁棒性。

在熟悉了实验所用数据集中的文本类别、分布和长度后，我首先对文本进行了标记化(Tokenization)，这是训练前必须进行的一个步骤，因为模型不能直接接收原始字符串作为输入。实验中尝试了三种 Tokenization 方式：字符标记化(Caracter Tokenization)与单词标记化(Word Tokenization)分别以字符和单词为单位进行，这两种做法看起来简单直接，但前者忽略了文本结构而后者带来了庞大的参数量，都不利于模型的训练；子词标记化(Subword Tokenization)则是两者的折中，这使得常见词能够被作为整体理解，而罕见词和拼写错误也能被高效处理。

训练模型时，我采用了特征提取(Feature Extraction)和微调(Fine-tune)两种常用的方法并进行了比较。一般将 Transformer 模型的自注意力层(Self-attention Layer)称作 Body，而将全连接层(Fully Connected Layer)和 Softmax 称作 Head。Feature Extraction 中不改变 Body，训练时只对 Head 中的参数进行调整；实验中对比了随机森林(Random Forest)、支持向量机(Support Vector Machine)、逻辑回归(Logistic Regression)三种分类模型的准确率，并与总选择最频繁类别的简单分类器的准确率比较。Fine-tune 则会训练包括 Body 和 Head 在内的整个模型，这会消耗更多计算资源，但也能达到更好的预测效果；而其中超参数的设置也会对模型的性能有很大的影响，分别微调各超参数，并绘制模型 Accuracy 或 F1 与其的关系曲线，可得出实验条件下各超参数的最优取值区间，在模型预测取得相近效果时，尽量缩短训练时间。通过绘制混淆矩阵(Confusion matrix)展现真实标签和预测标签之间的关系，我们不仅能更直观地看出模型的总体表现，还能了解模型在不同类别文本上的分类情况。

最后，通过展示测试中损失值(Loss)最大和最小的样本及其标签，我们可以对模型的性能进行进一步分析。Loss 值是模型预测值与真实值差距的表征，如果它较大就意味着模型对该样本产生了误判。预测结果与真实值非常接近的样本可能具有模型易于识别的特点；误差极大的样本则反映了模型存在的缺陷，这既可能来自模型本身的犯错倾向，也可能是由于样本具有一定的迷惑性。

3. 实验 Experiments

3.1 实验设置 Experimental Setup

本实验使用的数据集包含"sadness"，"joy"，"love"，"anger"，"fear"，"surprise"六种情感类别。每个标签下都有一些推文，数量从几百到几千不等，最多的是"joy"和"sadness"两类，最少的是"surprise"，这种不平衡的数据分布会对实验结果有一定影响。文本长度大都集中在 10-30 词，基本不超过 50 词，这样小规模的文本方便了我们的处理。

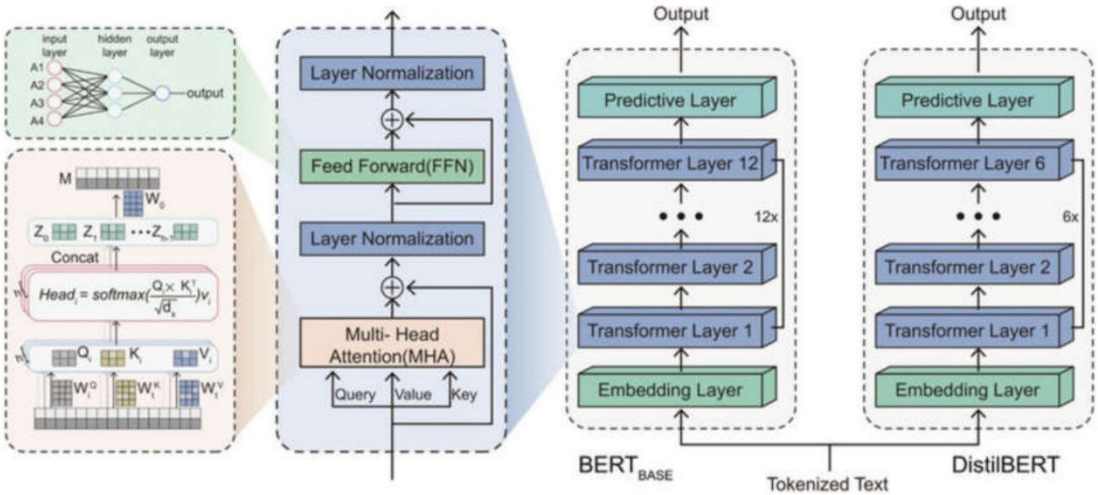


Figure 1: Diagram of BERT BASE and DistilBERT model architecture (Sajid, 2024).

实验中使用了 Transformer 架构的 DistilBERT 模型，这是一种轻量级的 BERT 变体(Figure 1)，在保持较高性能的同时简化了模型、提高了计算效率。相比于 BERT 的结构，它去除了 Token-type embeddings 和 Pooler，且 Transformer 层数减半，更适合在资源有限的情况下使用。

在对模型采用 Fine-tune 训练时需要设置一些超参数，如训练轮数(Number of Epochs) num_train_epochs，学习率(Learning Rate) learning_rate，权重衰减(Weight Decay) weight_decay 等。我通过预先调试，确定各超参数默认值分别为 num_train_epochs =10, learning_rate= 1e-5, weight_decay=0.01。在探究这些超参数的最优取值时，无关项设置为默认值，目标项的取值区间分别为：num_train_epochs 1-10, learning_rate 0-0.001, weight_decay 0-0.006。这些区间都将默认值包含在内，以在默认值附近探究最优取值。

最后在对模型预测结果最好和最坏的样本分析之后，我针对其可能犯的错误构造了 5 条对抗样本，分析模型在这些样本上的表现有利于我们理解其弱点，从而能够有目的地探索提升稳定性的方法。

3.2 实验结果 Main Results

实验中首先了解了数据集和模型的基本情况，并对文本数据作了必要的处理，这是进行后续实验的基础。随后采用特征提取(Feature Extraction)方法训练，对比不同的分类模型发现，随机森林(Random Forest)、支持向量机(Support Vector Machine)、逻辑回归(Logistic Regression)三种模型在测试中的准确率分别达到了 0.5065，0.583，0.635，在实验条件下三者准确率依次增加，且相较于总选择最频繁类别的简单分类器 0.352 的基准均有一定的预测效果。将预测结果通过 Confusion matrix 展示(Figure 2)，可以看出样本量最大的 joy 和 sadness 拥有较高的准确率；love 和 surprise 很容易被误判为快乐，其误判频率甚至超过了正确率；anger 也常会被误判为 sadness。这些错误的产生是很容易理解的，因为我们在进行隐藏状态抽取后的可视化中便能发现它们占据空间的相似性。

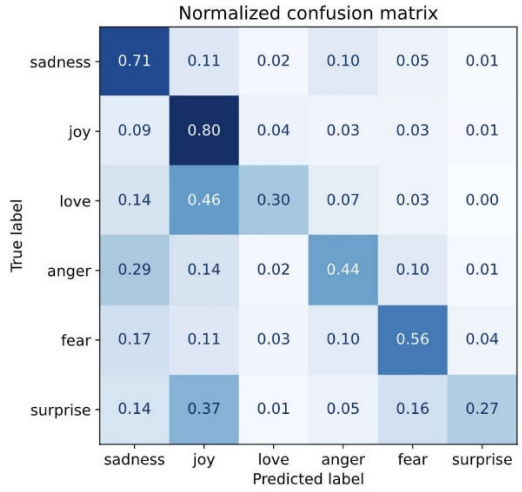


Figure 2: Feature Extraction confusion matrix.

Epoch	Training Loss	Validation Loss	Accuracy	F1
1	0.532000	0.242841	0.925500	0.926523
2	0.195400	0.204243	0.933000	0.932875
3	0.156400	0.208197	0.938000	0.938567
4	0.125900	0.247839	0.938000	0.938563
5	0.101400	0.252652	0.939500	0.939741
6	0.072500	0.306929	0.940000	0.939955
7	0.059400	0.351036	0.933500	0.933450
8	0.045600	0.363606	0.934000	0.934210
9	0.032600	0.377544	0.936000	0.935883
10	0.027300	0.363042	0.938500	0.938419

Figure 3: Accuracy & F1 of the model over a training time of 10 epochs.

采用微调(Fine-tune)方法训练 10 个 Epoch，开始时模型 Accuracy 和 F1 有所提升，最终稳定在 0.93-0.94 之间(Figure 3)，这说明训练中模型性能已达上限，继续延长训练过程并没有提升模型效果，反而耗费更多时间。

Learning Rate 用于控制训练过程中每次迭代的步长，即学习的速率。实验中当 Learning Rate 取 1e-5 时模型性能达到最优，而取值很接近于 0 或较大时则会趋向于总是预测频率最高的样本种类，无训练效果(Figure 4)。这是由于 Learning Rate 极小会使得学习速率很慢，难以在有限的训练过程中达到效果，而过大则会导致模型参数很难在训练中收敛，故模型性能下降。

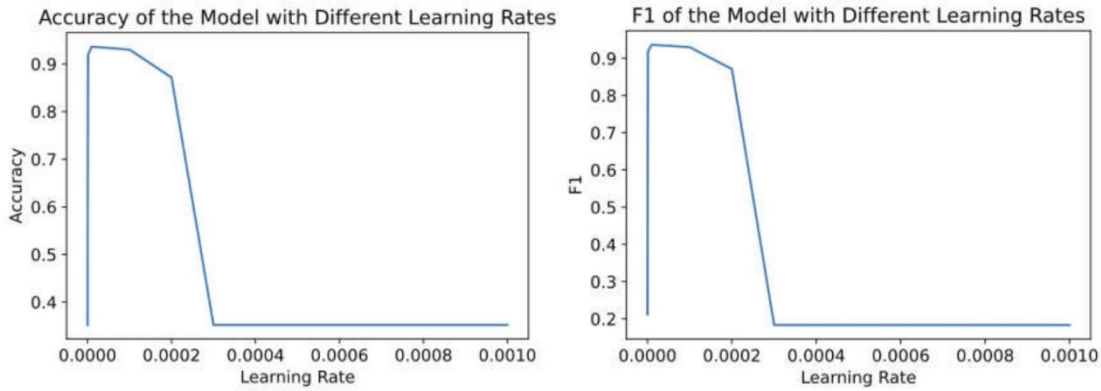


Figure 4: Accuracy & F1 of the model with different learning rates

Weight Decay 是在 L2 正则化中引入的系数，表征对系数的数值过大的惩罚力度，用于降低模型复杂性、防止过拟合。实验得到该参数设置不同时的模型效果，实验中 0-0.006 的 Weight Decay 都能让模型性能达到较高水平，其中 0.003 左右效果最佳。这说明实验中模型并没有发生明显的过拟合。

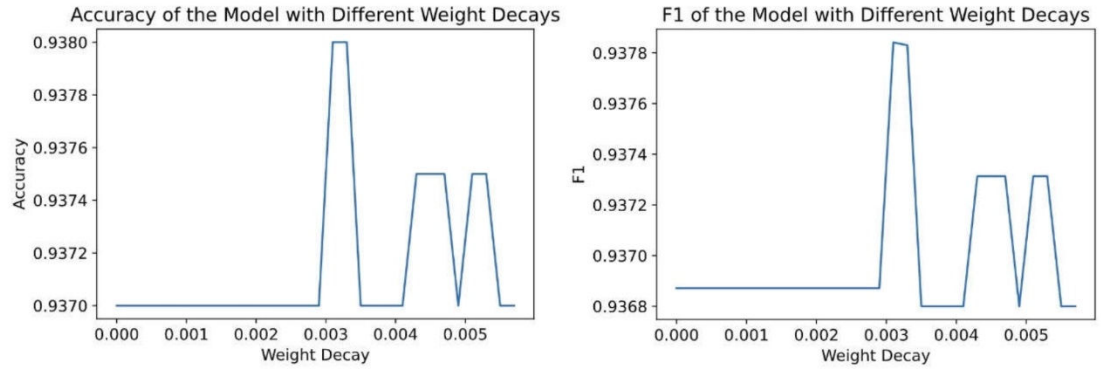


Figure 5: Accuracy & F1 of the model with different weight decays

将超参数重新设置为实验中取得最好效果的值，再次训练后模型的性能得到优化，Accuracy 和 F1 均接近 0.94。将该模型的预测结果通过 Confusion matrix 展示(Figure 6)，可以看出模型在各类样本上都取得了很高的准确率，表现出了比较理想的对角线，且样本量最大的 joy 和 sadness 依旧拥有最高的准确率；相对而言，love, surprise 与 fear 更容易被误判为其他情感。

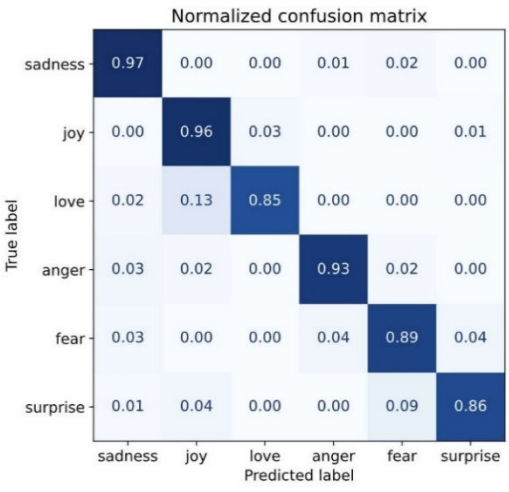


Figure 6: Fine-tune confusion matrix.

	text	label	predicted_label	loss
882	i feel badly about reneging on my commitment t...	love	sadness	12.939517
1801	i feel that he was being overshadowed by the s...	love	sadness	12.933402
1919	i should admit when consuming alcohol myself i...	fear	sadness	11.418999
1392	i still dont know how i feel i hated getting w...	anger	sadness	11.157487
292	i can say is that i feel like myself when i pu...	love	joy	11.025783
1521	i could get fucking stuffed in fucking chocola...	surprise	fear	10.914606
1422	i just act how i feel im becoming what ive alw...	anger	sadness	10.615935
1950	i as representative of everything thats wrong ...	surprise	sadness	10.478974
1757	i feel like there s a reason to buy another to...	anger	joy	10.066229
909	i cant stop the joyful tears from flowing as i...	love	joy	10.005462
	text	**label**	**predicted_label**	**loss**
1396	i feel so hopeless and unloved and unwanted	sadness	sadness	0.000009
574	i feel strangely defeated	sadness	sadness	0.000009
650	i am still feeling gloomy and down	sadness	sadness	0.000009
1954	i feel beaten and discouraged	sadness	sadness	0.000009
1665	i feel a lil bit gloomy	sadness	sadness	0.000009
375	i mention that i feel really unwelcome	sadness	sadness	0.000009
368	i have to admit that i m feeling quite gloomy ...	sadness	sadness	0.000009
1886	i feel unloved and know im hated	sadness	sadness	0.000009
58	i appeared in his office stony expression back...	sadness	sadness	0.000009
66	i look and feel miserable	sadness	sadness	0.000010

Figure 7: Predictions with the largest or smallest loss

通过对测试中 Loss 最大和最小的样本进行分析,不难发现模型对 sadness 有着非常精准的识别，不过这也带来了许多将其他情感误判为 sadness 的情况，这可能是因为 sadness 有较大的样本量且往往含有带明显感情色彩的词汇。而让模型产生误判的文本也具有一些特征，如情感表达委婉、句子结构复杂，有时含有否定、修辞、俗语等语言现象，模型对不常出现的情况可能无法准确判断；一些文本本身也具有相对复杂的情感，love 和 surprise 等情感往往是建立在其他情感的基础上的，这类句子也对模型有一定的迷惑性。针对模型的这些弱点构造对抗样本，发现模型对人们习以为常的一些表达方式无从下手，有时甚至对多种类别都给出了一定的可能性，未能提供精准的情感解读。实验中的模型可能对明显的情感词汇有很好的识别力，但很难理解语句中的言外之意。

4. 总结 Conclusion

本次实验通过训练 Transformer 模型实现文本情感分类,体会了文本信息抽取的基本流程，也对不同训练方法的预测效果进行了比较分析。实验发现，采用特征提取(Feature Extraction)方法训练能在较短时间内取得一定的分类效果，不同分类器的准确率也有差别;而微调(Fine-tune)方法则具有更高的精度上限，为达到这一上限须对超参数进行合理的设置，并进行足够时长的训练；模型出现的错误对于进一步优化至关重要，样本和模型两者都可能导致误判。如今文本处理需求日益增长，选择分类模型时我们也更应当结合实际，进行合理的调试与设置。随着技术的进步，这一领域的发展也必将给我们带来更多便利。